



PCA

Introdução ao Reconhecimento de Padrões
Turma TB

Gabriel Vaz Cançado Ferreira

Matrícula: 2021015194


1. Base de faces Olivetti

A base de dados foi obtida pela função `fetch_olivetti_faces()` disponível na biblioteca `python sklearn.datasets`.



2. Redução de dimensionalidade

Para reduzir a dimensionalidade do problema precisamos determinar até qual componente há relevância ao fazermos a decomposição em componentes principais. Na imagem a seguir podemos ver que a última componente que contribui para mais de 1% da variância é a 15. Logo, podemos reduzir o problema para 15 componentes.



3. Experimento

Para a realização do experimento realizamos o seguinte procedimento. Para um range de train/test ratios de 0.1 a 0.9, foram feitas 10 divisões aleatórias entre dados de treinamento e dados de teste, mantendo-se as proporções entre as classes. Por fim, usamos um modelo Naive Bayes para prever a classe com base na imagem reduzida a 15 componentes. Os resultados obtidos podem ser vistos a seguir:

Test size: 10.0% Mean Accuracy: 0.8275 Std Dev: 0.0453

Test size: 20.0% Mean Accuracy: 0.8275 Std Dev: 0.0249

Test size: 30.0% Mean Accuracy: 0.8067 Std Dev: 0.0213

Test size: 40.0% Mean Accuracy: 0.7625 Std Dev: 0.0379

Test size: 50.0% Mean Accuracy: 0.7210 Std Dev: 0.0431

Test size: 60.0% Mean Accuracy: 0.6367 Std Dev: 0.0427

Test size: 70.0% Mean Accuracy: 0.5018 Std Dev: 0.0448

Test size: 80.0% Mean Accuracy: 0.2497 Std Dev: 0.0435

Test size: 90.0% Mean Accuracy: 0.4592 Std Dev: 0.0274

4. Conclusão

A partir dos resultados obtidos, observa-se uma tendência clara de redução da acurácia média conforme aumenta a proporção dos dados de teste. Quando apenas 10% ou 20% dos dados são reservados para teste, o modelo Naive Bayes alcança uma acurácia média de aproximadamente 82,7%, indicando bom desempenho quando há uma quantidade significativa de dados disponíveis para treinamento.

À medida que o tamanho do conjunto de teste aumenta (e, portanto, o conjunto de treinamento diminui), o desempenho do modelo se deteriora progressivamente. Esse comportamento é esperado, pois o Naive Bayes depende fortemente de estimativas de probabilidade baseadas na distribuição dos dados — quanto menor o conjunto de treinamento, menos representativas são essas estimativas, levando a previsões menos precisas.

A partir de test sizes acima de 50%, a queda na acurácia torna-se mais acentuada, chegando a apenas ~25% para 80% de dados de teste, o que indica que o modelo praticamente perde capacidade de generalização. Curiosamente, o valor de 90% de teste apresenta uma leve recuperação (45,9%), possivelmente devido à aleatoriedade

das divisões e ao pequeno número de amostras de treinamento ainda conter padrões específicos de algumas classes.