

Exercício – Estimação de Densidade em Problema 2D Multimodal

Contexto

Considere um problema em que os dados não seguem uma única distribuição Gaussiana simples, mas sim uma **mistura de distribuições** em duas dimensões. Esse tipo de problema é chamado **multimodal**, pois a densidade apresenta **múltiplos picos** (múltiplos "modos").

Uma forma de estimar a densidade de distribuições multimodais é utilizar a **Estimativa de Densidade por Núcleos (Kernel Density Estimation – KDE)**.

Tarefas

1. Geração de Dados Multimodais:

- Gere duas classes multimodais como no exemplo abaixo.

```
N<-30
NC1 = N*4
m1<-c(1,1)
m2<-c(1,4)
m5<-c(3,5)
m3<-c(5,5)
m4<-c(3.5,3)
m6<-c(5,1)

sig = 0.4

xc1<-matrix(rnorm(N*2,sd=sig),nrow = N,ncol = 2)+matrix(m1,nrow = N,ncol=2,byrow = T)
xc1b<-matrix(rnorm(N*2,sd=sig),nrow = N,ncol = 2)+matrix(m2,nrow = N,ncol=2,byrow = T)
xc1c<-matrix(rnorm(N*2,sd=sig),nrow = N,ncol = 2)+matrix(m5,nrow = N,ncol=2,byrow = T)
xc1d<-matrix(rnorm(N*2,sd=sig),nrow = N,ncol = 2)+matrix(m3,nrow = N,ncol=2,byrow = T)
xc2<-matrix(rnorm(N*2,sd=sig),nrow = N,ncol = 2)+matrix(m4,nrow = N,ncol=2,byrow = T)
xc2b<-matrix(rnorm(N*2,sd=sig),nrow = N,ncol = 2)+matrix(m6,nrow = N,ncol=2,byrow = T)

xc1 <-rbind(xc1,xc1b,xc1c,xc1d)
xc2 <-rbind(xc2,xc2b)
```

- Plote os pontos no plano XY com cores distintas para cada grupo.

```
plot(xc1[,1],xc1[,2],col='red',xlim=c(0,6),ylim=c(0,6), xlab="", ylab="")
par(new=T)
plot(xc2[,1],xc2[,2],col='blue',xlim=c(0,6),ylim=c(0,6))
```

2. Estimativa por KDE:

- Para cada ponto da amostra, associe um núcleo Gaussiano (com covariância definida).
- Construa a superfície da densidade resultante como a soma desses núcleos.
- Visualize a densidade estimada em:
 - **Mapa de calor (2D)** mostrando as regiões de maior densidade.
 - **Superfície 3D (perspectiva)** mostrando os diferentes picos da distribuição.

3. Análise:

- Compare a densidade obtida por KDE com as distribuições originais (uma gaussiana para cada grupo).
- Explique por que a KDE consegue capturar a natureza multimodal da distribuição.
- Discuta como a **largura da banda (covariância dos núcleos)** afeta o resultado (picos mais definidos vs. Suavizados).
- Se utilizarmos uma única Gaussiana para modelar os dados multimodais, o que acontece com a superfície de densidade?
- Como o número de pontos influencia a forma da superfície estimada pelo KDE?
- Como a escolha da matriz de covariância dos núcleos afeta a detecção dos diferentes modos da distribuição?